

1. Introducción

El presente proyecto tiene como objetivo realizar un **análisis completo de datos cinematográficos** a partir de dos fuentes distintas de IMDB:

- un conjunto de datos de **películas** con información financiera y descriptiva
- un conjunto de datos de **reviews** con análisis de sentimiento

El proyecto abarca **todo el ciclo de un proyecto de Data Analytics**: adquisición de datos, limpieza, transformación, análisis exploratorio, creación de métricas y visualización mediante un dashboard interactivo en Power BI.

2. Objetivos del proyecto

Los principales objetivos son:

- Integrar datos procedentes de **dos fuentes diferentes**
- Limpiar y transformar los datos para su análisis
- Generar métricas de negocio relevantes (beneficio, ROI)
- Analizar la relación entre presupuesto, ingresos y rentabilidad
- Identificar patrones por género cinematográfico
- Construir un **dashboard interactivo** que permita explorar los resultados

3. Descripción de los datasets

3.1 Dataset de películas (IMDB Movies)

Contiene información estructural y financiera de las películas, entre otras:

- Título de la película
- Género
- Fecha de estreno
- Presupuesto
- Ingresos

- País
- Idioma original
- Puntuación media

Este dataset constituye la **base principal del análisis**.

3.2 Dataset de reviews (IMDB Reviews)

Incluye:

- Texto de la reseña
- Clasificación del sentimiento (positivo / negativo)

Este dataset se utiliza para **extraer métricas agregadas de percepción del público**, que posteriormente enriquecen el dataset de películas.

4. Metodología y pipeline de datos

4.1 Carga y exploración inicial

Los datos se cargan en Python usando pandas, revisando:

- estructura
- tipos de datos
- valores nulos
- duplicados

4.2 Limpieza y transformación

Se aplican las siguientes acciones:

- Eliminación de duplicados
- Eliminación de filas con valores nulos críticos
- Normalización de columnas financieras
- Renombrado de columnas para mayor claridad
- Conversión de fechas a formato correcto

Los datasets limpios se almacenan en la carpeta `/data/processed`.

4.3 Enriquecimiento con métricas de reviews

Dado que ambos datasets **no comparten una clave directa**, se opta por una estrategia de **agregación**:

- Cálculo del porcentaje global de reviews positivas y negativas
- Incorporación de estas métricas al dataset de películas

Este enfoque permite **combinar información financiera y percepción del público**, manteniendo coherencia analítica.

4.4 Creación del dataset final

El dataset final incluye:

- Información estructural de las películas
- Métricas financieras
- Métricas derivadas:
 - Beneficio
 - ROI (Return on Investment)

Este dataset supera las **50.000 filas y 20 columnas**, cumpliendo los requisitos del proyecto.

5. Análisis exploratorio (EDA)

Durante el análisis se estudian, entre otros:

- Distribución de presupuestos e ingresos
- Relación entre presupuesto e ingresos
- Rentabilidad por género
- Identificación de películas altamente rentables
- Análisis de outliers

Uno de los principales hallazgos es que **un mayor presupuesto no garantiza mayor rentabilidad**, lo que se visualiza claramente en los gráficos de dispersión.

6. Dashboard en Power BI

Se desarrolla un dashboard interactivo que incluye:

KPIs principales

- Ingresos totales
- Presupuesto total
- Beneficio total
- ROI

Visualizaciones

- Dispersión Presupuesto vs Ingresos
- Rentabilidad media por género
- Ranking de películas más rentables
- Tabla Top películas por ROI

Filtros interactivos

- Género
- Fecha de estreno
- Presupuesto

El dashboard permite explorar los datos de forma dinámica y responder a preguntas de negocio.

7. Conclusiones

Del análisis realizado se extraen varias conclusiones relevantes desde una perspectiva empresarial y de toma de decisiones:

1. Un mayor presupuesto no garantiza una mayor rentabilidad

El análisis muestra que, aunque existe cierta relación positiva entre presupuesto e ingresos, esta no se traduce necesariamente en un mayor ROI. Existen numerosas películas con presupuestos moderados que generan retornos significativamente superiores a producciones de alto coste.

Desde un punto de vista empresarial, invertir más capital no implica reducir el riesgo financiero.

2. El ROI es una métrica más adecuada que los ingresos absolutos para evaluar el éxito

Películas con ingresos muy elevados pueden presentar un ROI bajo debido a presupuestos excesivos. En cambio, producciones con ingresos más modestos pueden resultar altamente rentables.

Para la toma de decisiones estratégicas, el ROI ofrece una visión más realista del desempeño económico que los ingresos totales.

3. Existen diferencias claras de rentabilidad entre géneros cinematográficos

El análisis por género revela que algunos géneros presentan un ROI medio superior, mientras que otros, aunque populares, tienden a requerir inversiones más elevadas con retornos proporcionales menores.

Esta información es clave para orientar la asignación de presupuestos y priorizar tipos de proyectos con mayor potencial de retorno.

4. Las producciones de presupuesto medio presentan un equilibrio óptimo entre riesgo y retorno

El análisis sugiere que las películas con presupuestos intermedios concentran una parte importante de los proyectos más rentables, evitando tanto el riesgo de grandes inversiones como las limitaciones de producciones de muy bajo coste.

Desde una perspectiva empresarial, este segmento representa una estrategia de inversión más estable.

5. El dashboard permite identificar oportunidades y riesgos de forma rápida

Gracias a los KPIs, filtros y rankings, el dashboard desarrollado facilita la identificación inmediata de:

- géneros más rentables
- películas con mayor retorno
- rangos de presupuesto con mejor desempeño.

Esto convierte la herramienta en un apoyo directo a la toma de decisiones estratégicas.

En conjunto, el proyecto demuestra cómo el análisis de datos aplicado al sector cinematográfico puede aportar valor real al negocio, permitiendo optimizar inversiones, reducir riesgos y mejorar la rentabilidad de futuros proyectos.

8. Limitaciones y mejoras futuras

- Falta de una clave directa entre películas y reviews
- Análisis de sentimiento limitado a clasificación binaria
- Posible ampliación con:
 - análisis temporal
 - modelos predictivos
 - NLP más avanzado